Reviewer aS43

Rating: 4

Confidence: 3

Q1: Limited methodological and analytical novelty. The paper offers limited methodological novelty, as it primarily applies established annotation and evaluation procedures to a newly constructed Vietnamese dialect benchmark.

TL;DR: Hạn chế về tính mới của phương pháp; chỉ áp dụng các phương pháp đã có cho một benchmark mới → Gợi ý trả lời: nhấn mạnh lại rằng main contribution là benchmark.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Ghi lại step by step từ raw data sources —> processed dataset

---

Q2: The final quality of the benchmark is difficult to assess. Table 1 reports dual-review ratings but does not define the rating categories, explain how reviewers' judgments were combined, or clarify whether the ratings are pre- or post-adjudication. Define Yes, Partial, and No with examples; explain how reviewer ratings are combined and when Table 1 ratings were collected. Clarify how Partial/No cases were handled and report reviewer agreement and audit results.

TL;DR: Chi tiết hơn về "rating categories" trong Bảng 1.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Làm thế nào để derive ra được table 1, nêu guideline, giải thích dual review ratings, các ví dụ cụ thể (10 hard samples)

Q3: The claim that QA is the task most affected by dialectal variation is insufficiently supported. QA is evaluated using F1, whereas the other tasks use accuracy, making raw performance drops across tasks difficult to compare directly.

TL;DR: Giải thích tại sao QA dùng F1 làm main metric, các task khác lại không (?!); đồng thời tại sao QA bị ảnh hưởng nhiều nhất bởi phương ngữ.

Đưa ra ví dụ cụ thể.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q4: The paper lists the source datasets for the four tasks but does not report how the 400 source instances are distributed across tasks or explain the sampling basis. This makes it difficult to assess whether the benchmark has a balanced task composition and to reproduce the sample-selection process; Report the number of source instances selected from each dataset and task, and describe the sampling criteria and procedure.

TL;DR: Mô tả chi tiết về "400 source instances": source từ đâu? chọn như thế nào? tiêu chí ra sao? etc…

……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Choose diverse topics, excluding politics-related ones.

Đi lại dataset, report label distribution, sampling strategies.

Q5: Make cross-task comparisons more cautious. Report performance changes within each task, provide QA exact-match results alongside F1, and qualify the claim that QA is most affected, given the different metrics.

TL;DR: So sánh giữa các task khác nhau rõ ràng hơn → Gợi ý: vì sao task này cao, task kia thấp trên cùng 1 dialect; overall, các task cao thấp như nào, tại vì đâu?...

……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Ở đây chủ yếu nói về mismatch metric giữa các task nhưng lại kết luận là QA là task bị ảnh hưởng nặng nhất, nên thêm exact match evaluation cho task QA

Q6: However, its contribution is primarily dataset construction, and the analysis offers limited insight into the linguistic causes of model failures.

TL;DR: Suy nghĩ là bổ sung thêm 1 số analyses khác đa dạng hơn → Gợi ý: nên đào sâu về mặt ngôn ngữ học (chẳng hạn như các dialect miền trung thường khác biệt về mặt ngôn ngữ → test so sánh với dialect phổ thông trên 1-3 samples cụ thể.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Lấy 1 vài câu từ benchmark, phân tích output giữa các câu. Đưa ra insights về phương ngữ, ví dụ như một vài từ phổ thông mà mô hình thường bối rối khi gặp phải.

Reviewer S8qy

Rating: 4

Confidence: 4

Q1: For the lexicon-guided sampling, can you report how the 400 source instances differ from the full source pools in task label, length, and dialect-trigger density?

*TL;DR: Chi tiết hơn về "400 source instances" (GIỐNG Q4 của reviewer **aS43**)*

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q2: For the QA setting, can you provide an error analysis that separates failures in understanding the dialectal question from failures in aligning it with the Standard Vietnamese context?

TL;DR: Bổ sung error analysis về các lỗi.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Trích ra những câu QA đúng trên standard nhưng sai trên phương ngữ, tổng hợp lại và tìm ra pattern chung?

Q3: Since only 58.4% of rewrites fully pass dialect authenticity, can you report the main performance gaps and harmful-flip rates on this fully passing subset?

TL;DR: Làm rõ hơn về con số 58.4% ý nghĩa là gì, từ đó trả lời câu hỏi về main performance gaps và harmful-flip rates.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Misunderstanding → re-clarify

Reviewer sxJf20

Rating: 5

Confidence: 3

Q1:

1.1. The samples are not natural dialect utterances from real users. Instead, they are human-written rewrites enriched with dialect-triggering lexical items, creating a certain distribution mismatch between dataset observations and real-world user dialect inputs;

→ Họ tưởng annotator là người phổ thông và sử dụng rule based để rewrite; claim lại là họ là những người địa phương, các rules chỉ là để tham khảo để enrich dataset. Bản chất vẫn là dialect nhưng có kiểm soát hơn.

1.2. Given the distribution bias brought by human-rewritten dialect-enriched samples, could you briefly discuss how much this bias may alter your core experimental conclusions?

→ same as 1.1

TL;DR: Giải thích cách tạo data (reviewer đang khá critical vì các sample không "natural"). Đồng thời, đưa ra luận điểm giải thích liệu các dữ liệu hiện tại có phù hợp cho benchmark hay không.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q2:

2.1. There is no analysis of whether factors such as model parameter size, the proportion of dialect data in pretraining, and instruction-tuning improve dialect robustness. Only observational results are reported, without ablations for model-level influencing factors.

2.2. Without launching new large-scale experiments, could you briefly describe the observed trend between model parameter size and dialect robustness based on existing results?

TL;DR: Bổ sung analysis về tác động của các yếu tố: kích thước mô hình, tỷ lệ samples các dialects trong pretraining models, và instruction-tuning (ngoài ra, có thể suy nghĩ thêm nhiều ablation studies khác).

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q3: Prior work widely adopts dialect-to-standard normalization. This paper merely marks it as future work and provides no baseline results on the proposed benchmark. Consequently, readers cannot know how much performance loss can be recovered by such preprocessing. Could you explain why dialect-to-standard normalization baselines are absent here, and give a theoretical estimate of the performance recoverable via such preprocessing?

TL;DR: Bổ sung kết quả khi apply ViDia2Std. Phân tích thêm, nếu apply ViDia2Std, các "standardized texts" trông như thế nào về mặt text, đồng thời, các LLMs "treat" nó như thế nào? (Ngoài ra, xem thử các case mà "standardized texts" failed, để phân tích vì sao đã chuẩn hóa vẫn còn failed)

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q4: Dialect groups are defined at a coarse regional level, and fine-grained analysis of intra-provincial sub-dialects is absent. Could you clarify the practical constraints that prevent fine-grained analysis for intra-provincial sub-dialects?

TL;DR: Bổ sung một số analysis về các tỉnh, trên cùng 1 vùng-level → Gợi ý: trên cùng 1 region, pick 2-3 samples cho 1 tỉnh thành, và phân tích kết quả của nó, sau đó so sánh với các samples của tỉnh thành khác.

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Reviewer 78qm

Rating: 6

Confidence: 4

Q1: The evaluated LLMs are quite old. Perhaps the recently released and more advanced LLMs are more robust to Vietnamese dialects.

TL;DR: (Optional) chạy thêm một vài models khác mới hơn, đa dạng size hơn → Gợi ý:

(1) Open-weighted models (Large dense & MoE):

- *Qwen 3.8 27B và Qwen 3.6 35B A3B*
- *Gemma 4 31B IT và Gemma 4 26B A4B IT*

(2) Commercial models (High performance & Lightweight):

- *GPT 6.1 Sol High (hoặc Medium) và GPT 6 Luna (High)*
- *Claude Opus 5.5 High (hoặc Medium) và Claude Sonnet 5.5 (High)*

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Q2: Not enough detail and analysis regarding the rewrite dataset (how many words or characters that been rewritten in a sentence). Since the sample in Figure 1 only shows that the dialect variation is rewriting one word in the whole sentence. Please provide more detail of words or characters that been rewritten in a sentence.

TL;DR: Chi tiết hơn về cách xây dựng dataset (*GIỐNG Q4 của reviewer **aS43**)*

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Report thêm details về rewrite dataset, số lượng từ viết lại trung bình, từ loại, …

Q3: Evaluation mostly only evaluates model understanding towards dialect variation (given prompt in different dialect and evaluate the answer based on multiple choice exact match or token-level F1). No evaluation about model generation robustness. It will be valuable if add experiment regarding open-ended generation to analyze the consistency of the dialect. For example given prompt in dialect PNT3, will the model also reply with PNT3?

TL;DR: Hỏi về generation robustness. Kiểu là khi input hỏi bằng PNT3 thì output có trả lời bằng PNT3 không hay bằng ngôn ngữ phổ thông? và trả lời đúng/sai như nào? → Gợi ý: pick 2-3 samples cho một vài dialect và check generated output texts.

- *chạy với multi seeds = 3 (h)*

……..……..……..……..……..……..……..……..……..

→ <Answer Here>

<Answer Here>

<Answer Here>

Reviewer YqL6

Rating: 9

Confidence: 5